

Grundlagen

Standardform

min f(x) u.d.N. g_i(x) ≤ 0, h_j(x) = 0
x ∈ X

max f ≡ min(−f) (Vorzeichen am Wert beach-
ten).

Zulässige Menge F = {x : g_i ≤ 0, h_j = 0}.

Klassifikation

LP	f, g, h linear – Simplex, IPM
QP	f quadr., g/h linear – Aktive-M.
NLP	mind. eines nichtlin. – SQP, New- ton
Konvex	lokal = global
Glatt	f ∈ C^1 – Gradientenverfahren
Nichtglatt	Subgrad./Proximal
MIP/diskret	X ⊆ Z^n – B&B
Stochastisch	SAA, Stoch. Gradient

Konvexität

- Menge: ∀x, y ∈ C, λ ∈ [0, 1]: λx + (1 − λ)y ∈ C
- Funktion: f(λx + (1 − λ)y) ≤ λf(x) + (1 − λ)f(y)
- Strikt: < für x ≠ y, λ ∈ (0, 1)
- f ∈ C^2: konvex ⇔ ∇^2 f ⪰ 0 (PSD); strikt bei > 0
- Summe konv., max endlich vieler konv., fcoffin konv.

Hauptsatz: konvex ⇒ jedes lok. Min = glob. Min;
strikt konvex ⇒ eindeutig.

Optimalität (unbeschränkt)

Notw. 1. Ord.: ∇f(x*) = 0 (stationär).
Hinr. 2. Ord.: ∇f(x*)=0 ∧ ∇^2 f(x*) > 0 ⇒ strik-
tes lok. Min.
Konvex: ∇f(x*)=0 ⇒ glob. Min.

Lineare Optimierung

Standardform LP

min c^T x u.d.N. Ax = b, x ≥ 0

- max c^T x → min(−c^T x)
- a^T x ≤ β → a^T x + s = β, s ≥ 0 (Schlupf)
- a^T x ≥ β → a^T x − s = β, s ≥ 0 (Überschuss)
- Freie Var.: x = x^+ − x^−, x^± ≥ 0

Fundamentalsatz: endliches Optimum ⇒ optima-
le Ecke (Basislösung) existiert.

Simplex

1. **Opt.-Test:** alle red. Kosten c̄_j ≥ 0? → fertig.
2. **Pivot-Spalte:** wähle j mit c̄_j < 0 (negativster = Dantzig).
3. **Pivot-Zeile** (min-ratio): minim. b_i/a_ij unter a_ij > 0; sonst LP unbeschränkt.
4. **Pivot-Operation** um a_ij (Zeile teilen, andere reduzieren).

Bland-Regel (Tie → kleinster Index) verhindert
Zyklen bei Degeneration. Worst case exponentiell
(Klee-Minty), IPM polynomial.

Dualität

Primal: min c^T x, Ax ≥ b, x ≥ 0
Dual: max b^T y, A^T y ≤ c, y ≥ 0
n Var (P) n NB (D)
m NB (P) m Var (D)
x_j ≥ 0 D-NB j als ≤
x_j frei D-NB j als =
NB i als ≥ y_i ≥ 0
NB i als = y_i frei
c_j (Zielk.) D-RHS
b_i (RHS) D-Zielk.

Schwach: b^T y ≤ c^T x. **Stark:** endl. Opt. ⇒ beide
gleich.
Kompl. **Schlupf:** x_j^*(c_j − A^T_{·j} y^*) = 0,
y_i^*(A_i · x^* − b_i) = 0.

Nichtlineare Optimierung

1D-Verfahren

Bisektion auf f': f'(a)f'(b) < 0, halbieren –
linear.
Newton auf f': x_{k+1} = x_k − f'(x_k)/f''(x_k) –

Optimierungsverfahren

quadratisch.

Goldener Schnitt: ρ=(√5−1)/2 ≈ 0,618;
x_1=a+(1−ρ)(b−a), x_2=a+ρ(b−a); kleineres f
behalten.

Gradientenabstieg

x_{k+1} = x_k − α_k ∇f(x_k)

Armijo: f(x_k − α∇f) ≤ f(x_k) − c_1 α||∇f||^2, c_1 ∈
(0, 1/2).
Wolfe: Armijo + Krümmungsbed.
Konvergenzrate (Kondition κ): ((κ−1)/(κ+1))^2 –
langsam bei κ ≫ 1.

Newton & Quasi-Newton

x_{k+1} = x_k − [∇^2 f(x_k)]^{-1} ∇f(x_k)

- Quadratisch lokal; Hesse muss PD für Abstieg.
- Aufwand O(n^3)/Schritt; gedämpft mit Linese-
arch.
- **Levenberg-Marquardt:** (∇^2 f + λI)^{-1}.
- **BFGS:** approx. H^{-1} aus Gradientendiff., su-
perlinear.

Lagrange & KKT

L(x, λ, μ) = f(x) + ∑_i λ_i g_i(x) + ∑_j μ_j h_j(x)

- λ_i ≥ 0 (Ungl.), μ_j frei (Gl.).
KKT (notwendig bei reg. Punkt; bei konvex auch
hinreichend):
1. Station.: ∇f + ∑_i λ_i ∇g_i + ∑_j μ_j ∇h_j = 0
2. Primal-Zul.: g_i ≤ 0, h_j = 0
3. Dual-Zul.: λ_i ≥ 0
4. Kompl. Schlupf: λ_i · g_i = 0

Strafverfahren

Quadr. Penalty: f + ρ ∑ h_j^2 + ρ ∑ max(0, g_i)^2,
ρ → ∞.
Barriere/IPM: f − μ ∑ log(−g_i), μ → 0.

Gradientenfreie / Metaheuristiken

Direktsuche

Nelder-Mead: Simplex aus n+1 Punkten;
Schritte: Spiegelung → Expansion (wenn besser
als alle) / Kontraktion / Schrumpfung.
Koordinatenabstieg: zyklisch eine Variable
opt.
Hooke-Jeeves: Achsen-Schritte + Pattern Mo-
ve.

Simulated Annealing

1. Initial x_0, T_0; best = x_0.
2. Wiederhole bis T < T_min:
 - Nachbar x'; Δ = f(x') − f(x).
 - Akzeptiere wenn Δ < 0 oder rand() <
exp(−Δ/T).
 - Best updaten.
3. Cooling T_{k+1} = αT_k, α ∈ [0,9; 0,99].
Metropolis: P_accept = exp(−Δ/T). Log. Cooling
T_k = c / log(k+1) konv. zum Glob. (theor.).

Genetische Algorithmen

Selektion (Roulette/Turnier/Rang) – Crosso-
ver (One-Point/Uniform/BLX-α) – Mutation
(Gauss/Bit-Flip) – Ersetzung (μ, λ) vs. (μ+λ);
Elitismus bewahrt Beste.
CMA-ES: adaptive Kovarianzmatrix.

PSO

v_i ← w v_i + c_1 r_1 (p_i − x_i) + c_2 r_2 (g − x_i)

x_i ← x_i + v_i

w ∈ [0,4; 0,9] (linear fallend), c_1=c_2 ≈ 2, r_{1,2} ~
U[0,1]. p_i pers., g glob. Best.

ACO

p_{ij} ∝ τ_{ij}^α · η_{ij}^β, η_{ij}=1/d_{ij}, τ ver-
staerkt/verdunstet.

Mehrzieloptimierung

Pareto

Dominanz x ≺ y: ∀i: f_i(x) ≤ f_i(y) ∧ ∃j: f_j(x) <
f_j(y).
Pareto-optimal = nicht dominiert; Pareto-Front
= Bild der Pareto-Menge.

Verfahren

Gewichtete Summe: min ∑ w_i f_i, w_i ≥ 0,
∑ w_i=1 – bei nicht-konvexer Front nicht alle
Punkte erreichbar.
ε-Constraint: min f_1 u.d.N. f_j ≤ ε_j (j ≠ 1) –
auch nicht-konvex.
NSGA-II / SPEA2 / MOEA/D.

Qualitätsindikatoren

Hypervolumen (höher besser, Pareto-konform);
IGD (niedriger besser); **Spread**.

Verfahrenswahl-Matrix

LP	Simplex / IPM
QP	Aktive-M., IPM
NLP glatt	SQP, Newton, BFGS
Konvex	Newton/BFGS
Nicht-glatt	Subgrad., Proximal
MIP/diskret	B&B, Heuristik
Blackbox/verrauscht	Nelder-Mead, CMA-ES, Bayes
Nicht-konvex	Multi-Start, SA, GA, PSO
Mehrzielig	Gew. Sum., ε-C, NSGA-II
n < 100	Dense Newton, SLS- QP/IPOPT
n < 10^4	BFGS, sparse Newton, CG
n > 10^5 (DL)	L-BFGS, SGD/Adam

Klausur-Stolperfallen

- λ_i ≥ 0 nur bei Ungl.-NB; μ_j frei bei
Gleichungs-NB.
- Komplement. Schlupf bei KKT *immer* mit-
schreiben.
- Min-Ratio nur über a_{ij} > 0 (sonst LP unbe-
schränkt).
- Bland-Regel bei Degeneration aktivieren.
- Bei max Vorzeichenwechsel: Optimum
−(−c)^T x*.
- Gewichtete Summe verfehlt nicht-konvexe
Pareto-Fronten.
- Vor SA/GA: Problem konvex? dann New-
ton/BFGS.